

EdEval: 面向大语言模型评估中数据污染问题的动态解决方法

仲宝才¹, 杨帆²⁺

1. 成都东软学院 计算机与软件学院, 成都 611844

2. 暨南大学, 广州 510632

+ 通信作者 E-mail: yangfan@stu2024.jnu.edu.cn

摘要:随着大型语言模型(LLMs)在超大规模语料库上开展预训练,数据污染问题逐渐凸显,这对模型性能评估的准确性构成了直接威胁。提出了一种创新的动态数据评估方法EdEval(equal distribution dynamic evaluation),旨在降低数据污染对评估准确性的影响。EdEval通过提取核心知识点与主旨,确保生成的评估问题在本质上与静态数据一致,并结合联网检索对知识点进行深入阐述,生成具有高质量知识支撑的评估样本。此外,EdEval通过控制问题数量和复杂度,实现动态对齐与灵活调节,以匹配静态数据的难度水平并满足不同复杂度的需求。采用布鲁姆分类法,EdEval从记忆、理解、应用、分析、评价和创造六个维度对LLMs进行综合评估。实验结果表明,EdEval在多个数据集上有效减轻了数据污染的影响,显著提高了评估的公正性和准确性。

关键词:大语言模型;数据污染;动态数据评估;布鲁姆分类法

文献标志码:A **中图分类号:**TP391 **doi:**10.3778/j.issn.1002-8331.2502-0217

EdEval: Dynamic Method for Addressing Data Contamination Issues in Large Language Model Evaluation

ZHONG Baocai¹, YANG Fan²⁺

1. School of Computer and Software, Chengdu Neusoft University, Chengdu 611844, China

2. Jinan University, Guangzhou 510632, China

Abstract: With the pre-training of large language models (LLMs) on ultra-large-scale corpora, the issue of data contamination has gradually become prominent, directly threatening the accuracy of model performance evaluation. This study proposes an innovative dynamic data evaluation method called EdEval (equal distribution dynamic evaluation), aiming to reduce the impact of data contamination on evaluation accuracy. EdEval ensures that generated evaluation questions are essentially consistent with static data by extracting core knowledge points and main themes. It also integrates online retrieval to deeply elaborate on knowledge points, generating evaluation samples supported by high-quality knowledge. Additionally, EdEval achieves dynamic alignment and flexible adjustment by controlling the number and complexity of questions, matching the difficulty level of static data and meeting requirements for different complexity levels. Using Bloom's Taxonomy, EdEval comprehensively evaluates LLMs across six dimensions: remembering, understanding, applying, analyzing, evaluating, and creating. Experimental results show that EdEval effectively mitigates the impact of data contamination on multiple datasets, significantly improving the fairness and accuracy of evaluations.

Key words: large language model; data contamination; dynamic data evaluation; Bloom's taxonomy

大型语言模型(LLMs)凭借其在多种任务中的卓越性能,极大推动了自然语言处理(NLP)领域的发展^[1-2]。为评估LLMs在多任务中的表现,研究者们提出了多种基准测试。MMLU^[3]评估了模型在多个学科的知识与推理能力。BIG-Bench^[4]引入204个挑战性任务,探索模

型能力极限。AGIEval^[5]和C-Eval^[6]分别专注于标准化考试和中文高级知识的评估。

传统NLP和ML任务中,训练与测试数据的分离较为简单,但大语言模型依赖于在大规模互联网语料库上的预训练,许多广泛使用的基准测试同样源于网络资

基金项目:四川省哲学社会科学重点研究基地川菜发展研究中心科研项目(CC23W31)。

作者简介:仲宝才(1983—),男,硕士,教授,CCF会员,研究方向为计算机视觉、人工智能、数字化建设;杨帆(1996—),男,博士研究生,研究方向为人工智能、智慧教育。

收稿日期:2025-02-27 **修回日期:**2025-06-11 **文章编号:**1002-8331(2026)06-0214-11

源,这就无可避免地引发了数据污染问题^[3]。随着LLMs规模的扩大,训练数据和测试基准之间的重叠愈加普遍。这种基准测试污染可能导致对模型能力的误解,甚至产生误导性结论。尤其当评估基准与训练数据来源相同的网络资源时,数据污染的风险会显著增加,进而影响模型比较的公平性与有效性。

近期研究表明,数据污染在LLMs的评估中普遍存在^[1,7-8],会显著削弱评估结果的可信度,阻碍模型之间的公平比较。在LLMs的评估中,数据污染已成为关键挑战之一^[9]。

1 相关工作

许多研究探讨了数据污染的影响,Magar等^[10]和Jiang等^[11]研究了预训练阶段数据污染对语言模型性能的影响,分析了数据量和模型规模等对污染的影响。Palavalli等^[12]和Li等^[13]分析了数据污染对LLMs下游任务表现,以及零样本和少样本任务评估的影响。Dekoning等^[14]提出利用漏洞实现逃避增强学习(EAL),这是一种能避开大部分检测方法的有效污染技术。为应对数据污染问题,当前主要有两类解决方案:数据污染检测与动态数据评估^[15]。

数据污染检测方法旨在识别模型输出与训练数据之间的重叠^[16]。然而,由于一些闭源模型(如GPT系列)在生成过程中加入了特殊的过滤机制,导致检测效果受限。此外,这些方法主要集中于检测极端记忆(即模型直接复现训练数据),难以捕捉更隐蔽的污染形式。同时,由于封闭模型的数据集通常被视为商业机密,训练数据未公开,进一步加大了检测的难度。

近三年的数据污染检测方法包括通过交换样本和改变问题顺序检测数据泄露(PAC^[17]、Oren等^[18]、Ni等^[19]);基于困惑度检测污染(Xu等^[20]、Schwarzschild等^[21]);分析LLMs内部状态分布或识别低概率离群词(Min-K%+^[22]、Shi等^[23]);通过检测和校正输出分布识别污染(CDD和TED^[24])。还有如DetCon和ComiEval^[24]提供了基准评估效果的改进;ConStat^[25]通过比较基准性能检测污染;Golchin等^[26]结合引导指令与分类器检测;Yao等^[27]提出跨语言污染检测;Maini等^[28]则基于统计推断分析成员特征。这些方法虽然各具特色,但大多依赖模型的内置信息或复杂的分析手段,限制了其实际应用。

相比于数据污染检测,动态数据评估能够在很大程度上缓解数据污染问题,同时避免检测方法的固有局限性。现有的动态评估方法在不同领域取得了积极进展。例如,DYVAL^[7]提供了针对数学领域的动态数据生成方法;KIEval^[15]引入了多轮对话的评估机制;LatestEva^[29]在生成无污染数据集方面表现优异;SciEva^[30]强调通过全新问题设计来测试科学研究能力;Ying等^[31]提出了利用简单策略生成评估数据的方法;DyVal 2^[32]动态生成具

有可控复杂度的样本,有效评估推理能力与模型改进;Liu等^[33]则通过多项综合测试,全面考察中文LLMs在学科知识上的能力。

此外,一些方法通过生成变体、重述问题或移除相似样本减少数据污染并提升评估准确性。例如,CleanEval^[34]利用释义与语义检测优化样本,Mehrbakhsh等^[35]生成变体与重述问题以检测污染,Yang等^[36]过滤相似样本以降低过拟合风险;KIEval^[15]则通过多轮对话,评估模型的理解力与知识应用能力。这些研究为动态评估提供了多样化的策略,大幅提升了评估的公平性和可靠性。

然而,动态数据评估的实际应用仍面临一些挑战。一些方法在特定领域表现优异,但尚未实现广泛适用;部分方法在生成数据的可控性或答案准确性上存在改进空间;此外,如何在确保评估可靠性的同时提升稳定性和可扩展性,依然是动态评估领域的重要研究方向。

2 研究目标

本研究提出了一种名为EdEval(equal distribution dynamic evaluation)的动态数据评估方法,旨在通过动态生成同分布的评估样本,降低数据污染对LLMs评估结果的干扰。EdEval的创新点主要体现在以下几个方面:

(1)动态生成同分布评估数据。通过提取原题的知识点与主旨,结合联网检索对相关内容进行详尽扩展,从而生成与原题核心思想一致的新问题,确保数据的动态性与一致性。

(2)复杂度控制与动态对齐。设计了复杂度调控机制,动态调整问题难度,使生成数据既能与静态数据的难度水平匹配,又可满足不同复杂度的需求。

(3)多层次认知评估。采用布鲁姆分类法,从记忆、理解、应用、分析、评价和创造六个维度评估模型的能力,探讨LLMs在不同认知任务中的表现。

3 研究方法

EdEval动态生成数据集流程如图1所示,包括:数据预处理、知识点与主旨提取、联网检索、问题设计、复杂度控制和质量检查。

3.1 提示词优化

提示词对大模型输出质量有着显著的影响,为提升大模型的输出质量,采用基于多轮迭代的提示词优化策略,借助多个LLMs,如GPT-4o,不断调整和优化提示词设计,使输出结果更接近预期。优化过程如图2所示。

(1)示例选择。从预先选定的数据集中挑选1至5个代表性样例,作为Few-shot示例。

(2)初始提示词设计。基于示例设计提示词的初始版本,并将示例与任务需求嵌入提示词中,形成完整的输入。




图1 EdEval 流程

Fig.1 EdEval process




图2 提示词优化流程

Fig.2 Prompt optimization process

(3)模型生成与比对。将提示词与示例一并输入至 LLM 中,生成输出答案,并将其与标准答案进行对比,分析差异与不足。

(4)优化建议生成。将初始提示词、LLM 输出及标准答案一并输入至另一个 LLM 中,获取针对提示词的优化建议。

(5)提示词调整。基于优化建议,重新调整和改进行提示词,引导 LLMs 生成更接近预期的答案。

通过上述循环迭代的优化流程,提示词的质量得以持续提升,从而有效增强大模型生成内容的准确性与一致性。

3.2 数据预处理

数据输入到 EdEval 流程之前,需对数据进行格式调整与采样。鉴于计算资源与时间的限制,对数据集进行均匀采样,选取了 303 个样本。其中,300 个样本用于动态生成新数据,另外 3 个样本作为提示词中的示例 (few-shot)。数据集调整后的统一格式如图 3 所示。




图3 预处理数据格式

Fig.3 Preprocessing data format

均匀采样的数学公式:

$$i_k = \left\lfloor \frac{k \cdot (N-1)}{S} \right\rfloor, k = 0, 1, 2, \dots, S-1$$

其中, i_k 是采样后的第 k 个索引, N 是数据集的总大小, S 是采样的目标大小, $\lfloor x \rfloor$ 表示对 x 下取整。 $\frac{k \cdot (N-1)}{S}$ 的作用是将 k 均匀地映射到区间 $[0, N-1]$ 上,确保每

个采样点的间隔一致。通过取整 $\lfloor \cdot \rfloor$,将结果映射到有效的整数索引。

3.3 知识点与主旨提取

首先从采样的数据集种提取相应的知识点。在提取过程中,由LLMs自主生成知识点,需满足以下三点要求:(1)生成的知识点必须与问题相关;(2)着重总结与问题相关的宽泛概念或知识类别,而非具体的细节性解释;(3)生成格式需符合预定要求,若不符合,则重新调用LLMs进行生成。

随后,对问题进行主旨提取。大模型通过对问题的总结生成主旨内容,需满足以下两点要求:(1)主旨内容应涵盖问题背景与答案核心;(2)主旨内容需简洁明了,避免冗余表述。主旨内容在后续的联网检索与问题设计环节中发挥关键作用,确保新生成的问题在核心思想上与静态数据问题保持一致。

在提取知识点和主旨时,采用了few-shot策略,通过参考不同数据集提供的示例,以提升大模型生成内容的质量。总体而言,知识点用于刻画当前问题的不同方向,而主旨则聚焦于问题的核心思想。在生成新问题时,这种设计能够同时拓展不同方向的问题内容,并确保核心思想的一致性。知识点主旨提取示例如图4所示。




图4 知识点主旨提取示例

Fig.4 Example of main idea extraction of knowledge points

3.4 联网检索知识点详述

利用大语言模型的联网检索功能,将数据集中每个问题的题干、相关知识点及其对应的主旨内容作为输入,生成针对知识点的详尽解释,生成内容需要满足三点要求。(1)聚焦知识点。详细阐述的内容应紧密围绕输入的知识点进行,可以适当结合问题和主题内容提供背景或补充信息,但必须确保知识点作为核心。(2)简明段落。输出内容应为一段清晰、连贯的文字,避免冗余或过于简略,不包含分段或额外的修饰。(3)直截了当。输出内容必须全面且准确,逻辑清晰,紧密围绕主题,避免包含无关信息或含糊其辞。

每个问题关联一个主旨内容和多个知识点。为提

高生成的灵活性,设计知识点选择机制,通过参数控制所选知识点的数量。在实际测试中,生成一个知识点详述时,调用Qwen-Plus的API大约需要30 s。如果针对每个知识点都生成详述内容,将导致较大的时间和资金消耗。

为此,引入了知识点筛选策略:从知识点数组中随机选择指定数量的知识点进行处理。例如,当参数设定为2时,如果知识点数量超过2个,则随机选取2个;若知识点数量少于2个,则选择全部知识点。随后,遍历选定的知识点,并基于题干和主旨内容,生成与之相关的详述内容。联网检索知识点的示例如图5所示。




图5 联网检索示例

Fig.5 Example of online retrieval of knowledge points

3.5 问题设计

通过嵌入前述的静态数据问题、知识点、主旨和知识点详述到提示词中,生成两类新问题:普通新题和基于布鲁姆分类法^[37-38]的新题。生成的问题需满足以下要求:

- (1)高度关联性。问题、正确选项及答案必须能够直接从提供的文本内容中找到依据,并与主旨内容密切相关。
- (2)难度保持一致/更高/更低。问题复杂度和参考问题一致/略高/略低,确保问题不是简单的事实复述,而是要求学生深入理解、结合细节分析后才能得出正确答案。
- (3)选项合理且具备区分度。选项设计要逻辑清晰,避免过于明显的正确答案。至少包含一个强干扰项,旨在考察学生的细致阅读和推理能力。
- (4)避免外部依赖。问题内容及选项需完全基于提供的文本内容与主旨内容。如需引用内容,需直接将相关文本内容嵌入问题,而非使用“依据上文”等类似标注。避免生成依赖上下文而难以单独理解的问题。
- (5)答案唯一。确保只有一个选项是正确的,而其他选项虽然合理,却存在细微的错误或与主旨和文本内容不完全契合。
- (6)考察深层理解。设计的问题可以涉及推论、对比、方法分析、重点概念的应用等,以提高难度。
- (7)题干创新。问题形式不能与参考题过于相似,应体现创新能力,同时保持问题风格严谨、专业。
- (8)侧重点不同。生成的问题侧重点应与参考问题

问题设计示例

层级: 记忆
问题: 在正则表达式中, 哪个符号表示前面元素的零次或多次重复?
A: ? B: * C: + D: .
答案: B

层级: 理解
问题: 在正则表达式的语境中, 表达式(a|b)*表示什么?
A: 仅包含任意次数重复的“a”的任意字符串
B: 仅包含任意次数重复的“b”的任意字符串
C: 包括空字符串在内的“a”和“b”的任意组合
D: 以“a”或“b”开头且以“a”或“b”结尾的任意字符串
答案: C

层级: 应用
问题: 给定正则表达式(a* + b)*(c + d), 以下哪个正则表达式正确地应用了相同的模式?
A: (a|b)(c|d) B: (a+b)(c+d)
C: (ab)(c+d) D: (a+b)*(c+d)
答案: D

层级: 分析
问题: 正则表达式(a|b)*与a*在可能匹配的字符串方面有何不同?
A: 它们匹配完全相同的字符串集合

B: (a|b)* 可以匹配包含“b”的字符串, 而 a* 不能
C: a* 可以匹配包含“b”的字符串, 而 (a|b)* 不能
D: 它们都能匹配包含任意数量“a”以及“b”的字符串
答案: B

层级: 评价
问题: 考虑到正则表达式 (a* + b)*(c + d), 评价以下哪个陈述最能合理解释在这种情况下使用选择运算符 | 而非连接运算符 + 的原因?
A: | 运算符允许在“a”和“b”之间进行选择, 这对于匹配可能以“a”或“b”开头的模式是必要的
B: + 运算符用于一次或多次重复, 这对于可选元素并不适用
C: | 运算符对于匹配单个字符更高效
D: | 运算符用于匹配“a”或“b”, 但对于模式的有效性并非必要
答案: A

层级: 创造
问题: 如果你要基于模式 (a* + b)*(c + d) 创建一个新的正则表达式, 该表达式匹配以零个或多个“a”开头, 接着是一个或多个“b”, 并以“c”或“d”结尾的字符串, 那么这个正则表达式是什么?
A: (ab+)(c|d) B: (a+b)(c|d)
C: (a* + b+)(c|d) D: (a+b*)(c+d)
答案: C

图6 问题设计示例

Fig.6 Example of question design

不同。例如,若参考问题侧重于概念定义,则生成的问题可以聚焦方法应用、关键细节对比、优缺点分析或实际场景判断等其他角度。

(9)聚焦知识点。问题需围绕所提供的知识点展开,核心内容紧扣主旨内容。

对于基于布鲁姆分类法生成的新题,除需满足上述要求中的1~5和9外,还需满足:层级覆盖。每道题对应一个认知层级,覆盖布鲁姆六个层级,每层级仅一道题,即总共需要输出六道题。基于布鲁姆分类法的问题设计示例如图6所示。

3.6 问题复杂度控制

若不对LLMs生成问题的过程施加约束,其结果往往倾向于生成较简单的数据集。本文设计了问题难度调整流程如图7所示,以确保生成数据集的复杂度与静态数据集对齐。

在生成数据集的初始阶段,通过 few-shot 提示词工程引入复杂度对齐机制,以确保生成数据的复杂度接近预期。由于初始阶段复杂度对比误差较大,因此需要进一步调整,以将大模型生成的数据集复杂度控制在可接受的误差范围内。

具体而言,通过数据集在预设模型(如 Qwen-7B-Chat)上的准确率来间接衡量数据集的复杂度。新生成的数据集会被输入预设模型进行测试,计算模型的准确率,并以此得到问题难度的偏移量:




图7 问题难度调整流程——以对齐静态数据集为例

Fig.7 Process of adjusting question difficulty—taking alignment with static dataset as example

$$\Delta = s_{target} - s_{gen}$$

其中, s_{target} 表示期望的准确率(如与静态数据集对齐时,取静态数据集在预设模型上的准确率),而 s_{gen} 表示生成的新数据集在预设模型上的准确率。偏移量需满足 $|\Delta| < 5\%$ 。

调整策略:

(1)当 $\Delta > 5\%$:生成的数据集复杂度过高,此时从生成数据集中选择模型答错的问题,并对其进行重构,向简单方向调整。

(2)当 $\Delta < -5\%$:生成的数据集复杂度过低,此时从生成数据集中选择模型答对的问题,并对其进行重

构,向复杂方向调整。

每次重构后,重新对新生成的数据集进行测试,重复上述步骤,直至满足 $|\Delta| < 5\%$ 。通过该流程能够有效控制生成数据集的复杂度,使其与静态数据集或预设目标对齐。

3.7 质量控制

为了确保 EdEval 的每一步生成过程符合质量要求,引入了多模型投票检查机制,即采用多个 LLMs(包括 Doubao-pro-32k、Qwen-plus 和 GPT-4o-mini)进行质量评估。投票检查规则如下:

(1)若3个回答中至少2个判断为“通过”,则认为该问题质量合格。

(2)若未达到上述条件,则判定问题存在质量问题,并重新生成。

3.8 算法描述

本文提出的 EdEval 的算法如下所示:

算法 同分布动态评估(EdEval)

输入:静态评估数据集 D_{static} ,数据集采样数量 S ,知识点数量 K_{num} ,复杂度对齐阈值 ϵ ,布鲁姆认知层级 $Bloom$,大语言模型 LLM

输出:动态评估数据集 $D_{dynamic}$

1. 初始化知识点 KN 、主旨 $Purport$ 、知识点详述 $KNexplain$ 数组

2. $D'_{static} \leftarrow i_k = \left\lfloor \frac{k \cdot (N-1)}{S} \right\rfloor, k=0, 1, \dots, S-1, N = len(D_{static})$ # 数据集采样

3. for d_i in D'_{static} : # 遍历静态数据集 动态生成数据集模块

4. $kn_i \leftarrow LLM(d_i), n = len(kn_i)$ # 知识点提取

5. $KN \leftarrow kn_i = \begin{cases} rand_select(kn_i, K_{num}), n > K_{num} \\ kn_i, n \leq K_{num} \end{cases}$, # 知识点数量控制

6. $Purport \leftarrow p_i \leftarrow LLM(d_i)$ # 主旨提取

7. for $kn_{i,j}$ in kn_i : # 遍历知识点

8. $KNexplain \leftarrow e_{i,j} \leftarrow LLM_{net}(d_i, kn_{i,j}, p_i)$ # 联网检索与知识详述

9. $D_{dynamic} \leftarrow Q_{i,j} \leftarrow LLM(d_i, kn_{i,j}, p_i, e_{i,j}, Bloom)$

题目设计

10. $\Delta = LLM_{test}(D_{dynamic}) - LLM_{test}(D'_{static})$ # 计算 Δ

11. while $|\Delta| < \epsilon$: # 复杂度控制模块

12. $Q_{error} = Q_select_error(LLM_{test}(D_{dynamic}))$ # 找出模型答错的题目

13. $Q_{correct} = Q_select_correct(LLM_{test}(D_{dynamic}))$ # 找出模型答对的题目

14. $D_{dynamic} \leftarrow Q_{i,j} = \begin{cases} restructure(Q_{error}, simple), \Delta > 0 \\ restructure(Q_{correct}, complex), \Delta < 0 \end{cases}$

重构数据

15. $\Delta = LLM_{test}(D_{dynamic}) - LLM_{test}(D'_{static})$ # 重新计

算 Δ

16. for d_i in $D_{dynamic}$: # 遍历动态数据集 质量检测模块

17. if $Multi_LLM(d_i) == pass$: # 质量合格

18. continue

19. else: # 质量不合格

20. $D_{dynamic} \leftarrow restructure(d_i)$ # 重构数据

21. return $D_{dynamic}$

在 EdEval 算法中,分三大模块,动态生成数据集模块、复杂度控制模块、质量检测模块。在算法的第2、5步,通过对采样数量 S 与知识点数量 K_{num} 来控制 $D_{dynamic}$ 的大小;算法中的 LLM 、 LLM_{net} 、 LLM_{test} 、 $Multi_LLM$ 分别表示大语言模型、联网的大语言模型、使用大语言模型进行准确度测试、使用多个大语言模型进行检查;算法中 $restructure(Q, simple/complex)$ 表示使用大模型对题目 Q 进行重构, $simple$ 代表朝简单方向重构, $complex$ 表示朝复杂方向重构。如果没有 $simple/complex$,表示正常重构,没有偏向。

EdEval 各部分提示词参考模版见地址 <https://gitee.com/zhong-baocai/ed-eval-prompt-words.git>。

4 实验

对 EdEval 进行实验,验证三个目标:(1)评估数据污染对 EdEval 的影响;(2)评估 EdEval 在与静态数据集的复杂度对齐的能力;(3)评估 EdEval 生成多维度问题的能力。

4.1 实验设置

实验环境。采用的 Pytorch 版本为 2.3.0,Python 版本为 3.12,系统为 Ubuntu22.04,CUDA 版本为 12.1,使用的大模型训练框架为 LLaMA-Factory。GPU 为 RTX 4090D(24 GB),CPU 为 15 vCPU AMD EPYC 9754 128-Core Processor。

实验数据。实验中使用的数据集包括:ARC-Challenge^[39]和 MMLU^[11],每个数据集均生成了300个样本。为降低随机性对评估结果的干扰,每组生成的数据集均进行了5次独立评估,确保生成数据的复杂度与原数据集保持一致。

Few-Shot。在动态生成问题的过程中,采用了 Few-Shot 学习策略。知识点、主旨提取与详述,以及问题生成均采用 2-shot,由于 Bloom 分类任务使用 2-shot 会因上下文长度过长而导致生成质量下降,因此 Bloom 分类问题生成采用 1-shot。

模型设置。实验选用了9个 LLMs,其规模和访问方式各不相同,具体信息见表1。

表1 实验使用的LLMs表
Table 1 LLMs used in experiment

模型	来源	参数量/10 ⁹	方式
GPT4o ^[1-2]	OpenAI	—	API
DeepSeek-V3 ^[40-41]	DeepSeek	671	API
Qwen-plus ^[42]	Alibaba	—	API
Claude-3-5-haiku	Anthropic	—	API
Doubao-pro-32k	ByteDance	—	API
GLM-4-flash ^[43]	Tsinghua	—	API
Qwen-7B ^[42]	Alibaba	7	Weights
Llama3-8B ^[44]	Meta	8	Weights
GLM-4-9B ^[43]	Tsinghua	9	Weights

注：“—”表示未公开。

选用Qwen-plus生成知识点、主旨以及知识点详述，使用Doubao-pro-32对齐问题复杂度。大模型设置温度参数为0，以避免生成过程中随机性的干扰。

微调设置。微调过程中采用了LoRA方法，其具体配置如下：学习率设为 5×10^{-5} ，训练轮数为2，Batch Size为2，LoRA秩为8，缩放系数为16，随机丢弃率为0.1，LoRA+学习率比例为16。

4.2 数据概述

实验中采用的ARC-Challenge包含2 590个问题，该数据集核心研究问题是如何使AI模型能够理解和解决复杂的科学问题，这些问题通常涉及多步骤的逻辑推理。数据集的构建基于科学问答任务，涵盖了从小学到高中水平的科学问题。下面是数据集的一个例子：

George wants to warm his hands quickly by rubbing them. Which skin surface will produce the most heat?

- A dry palms
- B wet palms
- C palms covered with oil
- D palms covered with lotion

MMLU数据集涵盖57个学科领域，包括科学、人文和社会科学等。该数据集已被广泛应用于LLM的评估中，是衡量LLM能力的一个重要标准。下面是数据集的一个例子：

Find the degree for the given field extension $\mathbb{Q}(\sqrt{2}, \sqrt{3}, \sqrt{18})$ over $\mathbb{Q}$.

- A 0, B 4, C 2, D 6

4.3 评估指标

(1) 准确率 (Accuracy)

准确率通过比较模型输出与标准答案的匹配情况计算，公式如下：

$$P = \frac{T}{T + F}$$

其中， P 是准确率， T 为正确答案数， F 为错误答案数。

(2) 模型困惑度 (Perplexity)

模型困惑度衡量模型对生成序列的“不确定性”。具体计算流程如下：

① 单个Token的Log-Probability

模型输出每个Token的对数概率，计算时将自然对数转换为以2为底的对数：

$$\text{lb } P = \frac{\ln p}{\ln 2}$$

② 平均Log-Probability

对所有生成Token的对数概率取平均值：

$$\overline{\log P} = \frac{1}{N} \sum_{i=1}^N \text{lb } p_i$$

其中， N 为生成的Token数量。

③ 困惑度计算

基于平均Log-Probability，计算困惑度：

$$PPL = 2^{-\overline{\log P}}$$

④ 数据集整体困惑度

对数据集中所有样本的困惑度取算术平均：

$$PPL_{\text{dataset}} = \frac{1}{M} \sum_{j=1}^M PPL_j$$

其中， M 为数据集样本总数。 PPL_j 是第 j 个样本的困惑度。

4.4 数据污染微调测试

在本实验中使用静态数据集对小参数量的LLMs进行数据污染的微调。

在检验数据污染对小模型微调效果的影响时，分别使用两种模型进行对比：一种为干净模型(clean, CLN)，另一种为受到静态数据污染的模型(contamination, CTM)。实验结果通过不同数据集进行了对比分析，量化静态数据污染和动态数据生成方法对模型表现的影响。

如图8所示，CLN表示干净模型，CTM表示受到静态数据污染的模型，Static代表静态数据集，EdEval代表由EdEval方法生成的动态数据，Auto-Dataset代表由Auto-Dataset生成的动态数据，LatestEval代表由LatestEval生成的动态数据。图8对比了基于MMLU和ARC-Challenge两种数据集，并使用Qwen-7B-Chat、Llama3-8B-Instruct、GLM-4-9B-Chat三种方法的实验，每个子图表示静态数据集(Static)与EdEval、Auto-Dataset、LatestEval生成数据集在污染前后的LLMs的准确率。

从图8的每个子图的第一组静态数据柱状图(Static)可以看出，数据污染会让大模型的准确率虚高，提升20%以上准确率。但数据污染在动态生成数据上影响小，相较于LatestEval和Auto-Dataset，EdEval在污染模型中影响最小，且只有EdEval可以保持与静态数据基本一致的复杂度。

4.5 数据重构

实验以基于MMLU数据集为例，使用Qwen2-7B-Chat展示了EdEval通过数据重构来控制问题复杂度。实验中，EdEval通过多轮数据重构逐步调整生成数据的复杂度，使其最终与静态数据的复杂度基本一致。在图9




图8 三种方法在数据污染模型上的对比

Fig.8 Comparison of three methods on models with data contamination

中,虚线折线表示动态数据集在干净模型(CLN)的准确率变化;实线折线表示动态数据集在污染模型(CTM)的准确率变化;水平点线表示静态数据在干净模型上的基准准确率;横坐标表示重构次数,纵坐标表示准确




图9 EdEval 动态数据重构过程中模型准确率变化趋势

Fig.9 Accuracy trends of models during EdEval dynamic data reconstruction

率。从图9可以看出,随着数据重构次数的增加,无论模型受到污染与否,EdEval生成的数据复杂度都能逐渐提升(准确率越低,问题复杂度越高),最终 EdEval 生成的数据集准确率与静态数据基准准确率基本一致(准确率差距5%以内)。

4.6 布鲁姆认知分层

本实验展示了EdEval生成布鲁姆认知分层的问题,这些问题在数据污染前后的 Qwen-7B-Chat 上进行了准确率测试,然后绘制成如图10的雷达图。




图10 EdEval 基于布鲁姆生成数据的雷达图

Fig.10 Radar chart of EdEval for data generated based on Bloom

在图10中基于MMLU与ARC-Challenge两种数据集生成布鲁姆认知分层的问题,图中有内外两个重叠的雷达图,内侧两个重叠的六边形是MMLU的准确率雷达图,外侧两个重叠的六边形是ARC-Challenge的准确率雷达图,重叠的雷达图是污染前后模型的准确率,说明了EdEval生成的布鲁姆认知分层问题几乎不受数据污染的影响。另外也可以看出,两个数据集在“创造”和“应用”这两个层级的问题难度较高,而在“理解”和“评估”层级的问题难度较低。

4.7 投票检查

在本实验中,通过投票检查的方式,对EdEval、Auto-Dataset和LatestEval生成的数据集进行质量检查,使用三个LLM(Doubao-pro-32k、Qwen-plus和GPT-4o-mini)进行投票判断。具体规则为:若3个LLM中至少有2个判断通过,则认为该题的答案正确;否则,判定答案有误。

基于MMLU,对EdEval、Auto-Dataset和LatestEval生成数据集进行投票检查,其错误率分别为5.8%、9.0%、7.5%,可以看出EdEval的错误率最低,这表明EdEval在问题生成中的正确性优于Auto-Dataset和LatestEval方法。

同时,本文通过投票检查,找出错误的题目,进行题目重构,进一步降低错误率。

4.8 困惑度测试

在本实验中将静态数据与三种方法动态生成的数据集在数据污染前后的 Qwen-7B-Chat 上进行了困惑度测试。

从表2可以看出,静态数据在污染前后的LLM的困惑度整体显著下降,Δ值在0.2左右。动态数据生成方法中,EdEval的Δ值均在0.1以下,下降幅度小且表现稳定;相比之下,LatestEval的Δ值在0.1至0.2之间,而Auto-Dataset的Δ值在0.05至0.2之间,波动显著。另外,从表2中可以看出,静态数据和动态数据,在LLM上测试的困惑度均有所下降,这是因为动态生成的数据与静态数据属于同一题型,尽管问题不同,但微调使得模型对该题型更为熟悉,因此困惑度整体均有下降。

表2 三种动态数据在污染前后 Qwen 模型困惑度对比

Table 2 Perplexity comparison of Qwen before/after pollution with three dynamic datasets

Dataset	MMLU			ARC-Challenge		
	CLN	CTM	Δ↓	CLN	CTM	Δ↓
Static	1.31	1.14	0.17	1.24	1.01	0.23
EdEval	1.32	1.23	0.09	1.30	1.29	0.01
Auto-Dataset	1.22	1.16	0.06	1.21	1.03	0.18
LatestEval	1.20	1.07	0.13	1.20	1.06	0.14

4.9 性能测试

前面的实验使用的均是参数量较小的LLMs,在本实验中,使用前沿的LLMs对EdEval、Auto-Dataset、LatestEval进行测试。

由于无法对图11中的LLMs进行微调,所以在提示词中加入相应的静态数据来模拟数据污染的微调。CLN表示仅使用动态数据进行测试,CTM表示在动态数据的提示词中加入相应的静态数据。从图11中,可以看出EdEval生成的数据在各个模型上都是复杂度最高的,并且也几乎不受静态数据的影响。

由于GLM-4-flash严格的安全设置,约5%的动态生成问题被拒绝回答,导致其测试结果存在一定的波动性。另外由于DeepSeek API在使用期间(2025年2月)反应速度极慢,只进行了一遍测试。

5 结语

本文提出的EdEval方法在解决大语言模型(LLMs)评估中的数据污染问题上取得了显著成效。通过动态生成与静态数据一致的评估数据,EdEval不仅有效缓解了数据污染对模型评估的影响,还通过精确控制问题复杂度,确保了生成的数据集与静态数据集保持相同的分布。实验结果表明,EdEval在MMLU和ARC-Challenge数据集上的表现优于其他动态数据生成方法,尤其在生




图11 三种方法生成数据在多模型准确率对比

Fig.11 Accuracy comparison of data generated by three methods across multiple models

成数据复杂度控制和质量稳定性方面,EdEval展现了明显的优势。

在数据污染的影响下,静态数据的微调有效提升了模型性能,而动态数据生成方法则表现出不同程度的抗污染能力。与Auto-Dataset和LatestEval方法相比,EdEval能够更好地控制生成问题的复杂度与质量,同时,数据污染对模型的影响较小。尤其在复杂性控制方面,EdEval在不同认知层级和数据领域中的应用潜力突出,能够适应不同数据集的复杂度需求,从而为大语言模型评估提供了更加稳定和可靠的解决方案。

未来的研究可以进一步探索EdEval方法的可扩展性和多样性,尤其是在更多类型的数据集上进行验证与应用。如何进一步提升生成数据的多样性与适应性,优化数据生成算法,并减少生成过程中的潜在偏差和误差,将是未来研究的关键方向。

参考文献:

[1] ACHIAM J, ADLER S, AGARWAL S, et al.GPT-4 technical

- report[EB/OL].[2025-01-08].<https://arxiv.org/abs/2303.08774>.
- [2] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems, 2020:1877-1901.
- [3] HENDRYCKS D, BURNS C, BASART S, et al. Measuring massive multitask language understanding[C]//Proceedings of the 9th International Conference on Learning Representations, 2021.
- [4] SRIVASTAVA A, RASTOGI A, RAO A, et al. Beyond the imitation game: quantifying and extrapolating the capabilities of language models[J]. Transactions on Machine Learning Research, 2023, 5.
- [5] ZHONG W J, CUI R X, GUO Y D, et al. AGIEval: a human-centric benchmark for evaluating foundation models[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 2299-2314.
- [6] HUANG Y Z, BAI Y Z, ZHU Z H, et al. C-eval: a multi-level multi-discipline Chinese evaluation suite for foundation models[C]//Advances in Neural Information Processing Systems, 2023.
- [7] ZHU K J, CHEN J A, WANG J D, et al. DyVal: dynamic evaluation of large language models for reasoning tasks[C]//Proceedings of the 12th International Conference on Learning Representations, 2023.
- [8] LI Y C, GUO Y H, GUERIN F, et al. An open-source data contamination report for large language models[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 528-541.
- [9] DENG C Y, ZHAO Y L, HENG Y Z, et al. Unveiling the spectrum of data contamination in language model: a survey from detection to remediation[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 16078-16092.
- [10] MAGAR I, SCHWARTZ R. Data contamination: from memorization to exploitation[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2022: 157-165.
- [11] JIANG M H, LIU K Z, ZHONG M, et al. Investigating data contamination for pre-training language models[EB/OL].[2025-01-19].<https://arxiv.org/abs/2401.06059>.
- [12] PALAVALLI M, BERTSCH A, GORMLEY M. A taxonomy for data contamination in large language models[C]//Proceedings of the 1st Workshop on Data Contamination, 2024: 22-40.
- [13] LI C M, FLANIGAN J. Task contamination: language models may not be few-shot anymore[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence, 2024: 18471-18480.
- [14] DEKONINCK J, MÜLLER M N, BAADER M, et al. Evading data contamination detection for language models is (too) easy[EB/OL].[2025-01-22].<https://arxiv.org/abs/2402.02823>.
- [15] YU Z H, GAO C, YAO W J, et al. KIEval: a knowledge-grounded interactive evaluation framework for large language models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 5967-5985.
- [16] BALLOCCU S, SCHMIDTOVÁ P, LANGO M, et al. Leak, cheat, repeat: data contamination and evaluation malpractices in closed-source LLMs[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 67-93.
- [17] YE W T, HU J Q, LI L Y, et al. Data contamination calibration for black-box LLMs[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 10845-10861.
- [18] OREN Y, MEISTER N, CHATTERJI N, et al. Proving test set contamination in black box language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.
- [19] NI S W, KONG X T, LI C M, et al. Training on the benchmark is not all you need[C]//Proceedings of the 39th AAAI Conference on Artificial Intelligence, 2025: 24948-24956.
- [20] XU R J, WANG Z Z, FAN R Z, et al. Benchmarking benchmark leakage in large language models[EB/OL].[2025-01-24].<https://arxiv.org/abs/2404.18824>.
- [21] SCHWARZSCHILD A, FENG Z L, MAINI P, et al. Rethinking LLM memorization through the lens of adversarial compression[C]//Advances in Neural Information Processing Systems. New York: ACM, 2024: 56244-56267.
- [22] ZHANG J Y, SUN J W, YEATS E, et al. Min-K%++: improved baseline for detecting pre-training data from large language models[EB/OL].[2024-01-25].<https://arxiv.org/abs/2404.02936>.
- [23] SHI W J, AJITH A, XIA M Z, et al. Detecting pretraining data from large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.
- [24] DONG Y H, JIANG X, LIU H Y, et al. Generalization or memorization: data contamination and trustworthy evaluation for large language models[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 12039-12050.
- [25] DEKONINCK J, MÜLLER M, VECHEV M. ConStat: performance-based contamination detection in large language models[C]//Advances in Neural Information Processing Systems, 2024: 92420-92464.
- [26] GOLCHIN S, SURDEANU M. Time travel in LLMs: tracing data contamination in large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.
- [27] YAO F, ZHUANG Y F, SUN Z H, et al. Data contamination

- can cross language barriers[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing.Stroudsburg: ACL, 2024: 17864-17875.
- [28] DZIEDZIC A, JIA H R, MAINI P, et al.LLM dataset inference: did you train on my dataset? [C]//Advances in Neural Information Processing Systems, 2024: 124069-124092.
- [29] LI Y C, GUERIN F, LIN C H.LatestEval: addressing data contamination in language model evaluation through dynamic and time-sensitive test construction[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence, 2024: 18600-18607.
- [30] SUN L T, HAN Y, ZHAO Z H, et al.SciEval: a multi-level large language model evaluation benchmark for scientific research[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence, 2024: 19053-19061.
- [31] BAI Y S, CAO Y X, DING Z J, et al.Automating dataset updates towards reliable and timely evaluation of large language models[C]//Advances in Neural Information Processing Systems, 2024: 17106-17132.
- [32] ZHU K J, WANG J D, ZHAO Q L, et al.Dynamic evaluation of large language models by meta probing agents[C]//Proceedings of the 41st International Conference on Machine Learning.New York: ACM, 2024: 62599-62617.
- [33] LIU C, JIN R R, STEEDMAN M, et al.Evaluating Chinese large language models on discipline knowledge acquisition via memorization and robustness assessment[C]//Proceedings of the 1st Workshop on Data Contamination.Stroudsburg: ACL, 2024: 1-12.
- [34] ZHU W H, HAO H K, HE Z W, et al.CLEAN-EVAL: clean evaluation on contaminated large language models[C]//Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 835-847.
- [35] MEHRBAKHS B, GARIGLIOTTI D, MARTÍNEZ-PLUMED F, et al.Confounders in instance variation for the analysis of data contamination[C]//Proceedings of the 1st Workshop on Data Contamination.Stroudsburg: ACL, 2024: 13-21.
- [36] YANG S, CHIANG W L, ZHENG L M, et al.Rethinking benchmark and contamination for language models with rephrased samples[EB/OL].[2025-02-04].<https://arxiv.org/abs/2311.04850>.
- [37] KRATHWOHL D R.A revision of bloom's taxonomy: an overview[J].Theory Into Practice, 2002, 41(4): 212-218.
- [38] FOREHAND M.Bloom's taxonomy[J].Emerging Perspectives on Learning, Teaching, and Technology, 2010, 41(4): 47-56.
- [39] CLARK P, COWHEY I, ETZIONI O, et al.Think you have solved question answering? try ARC, the AI2 reasoning challenge[EB/OL].[2025-02-06].<https://arxiv.org/abs/1803.05457>.
- [40] GUO D Y, YANG D J, ZHANG H, et al.DeepSeek-R1: incentivizing reasoning capability in LLMs via reinforcement learning[EB/OL].[2025-02-07].<https://arxiv.org/abs/2501.12948>.
- [41] LIU A X, FENG B, XUE B, et al.DeepSeek-V3 technical report[EB/OL].[2025-02-07].<https://arxiv.org/abs/2412.19437>.
- [42] YANG A, YANG B S, ZHANG B C, et al.Qwen2.5 technical report[EB/OL].[2025-02-07].<https://arxiv.org/abs/2412.15115>.
- [43] ZENG A H, XU B, WANG B W, et al.ChatGLM: a family of large language models from GLM-130B to GLM-4 all tools[EB/OL].[2025-02-07].<https://arxiv.org/abs/2406.12793>.
- [44] DUBEY A, JAUHRI A, PANDEY A, et al.The LLaMA3 herd of models[EB/OL].[2025-02-07].<https://arxiv.org/abs/2407.21783>.