

文章编号:1007-5321(2026)02-0001-08

DOI:10.13190/j.jbupt.2025-108

大模型指导下对信道噪声高鲁棒的联合信源信道编码算法

弓楚琦, 郭彩丽, 丁魁元, 孙启政

(北京邮电大学 信息与通信工程学院, 北京 100876)

摘要: 大模型显著提升了语义通信系统的语义表征与理解能力,但其庞大的参数量导致计算开销和推理时延显著增加,限制了系统的实用性。知识蒸馏虽然能够将大模型知识迁移至轻量级编码器以降低模型规模和复杂度,但在低信噪比(SNR)条件下往往会削弱系统的鲁棒性。针对上述问题,提出了一种鲁棒自知识蒸馏编码算法。该算法首先对大模型进行微调,并针对其编码得到的语义特征,在接收端引入2个结构相同的解码器,分别预测无噪和加噪传输条件下的解码输出。其中,无噪条件下的解码器作为教师模型,通过自蒸馏指导加噪条件下解码器的训练,从而增强解码端对信道噪声的鲁棒性。在此基础上,将大模型的语义表征能力蒸馏至轻量级编码器,在推理阶段采用经鲁棒增强训练得到的加噪解码器进行语义解码。实验结果表明,所提算法能够在极低SNR的情况下,图像分类任务准确率提升了约2.5倍。

关键词: 语义通信; 知识蒸馏; 信道噪声; 大模型

中图分类号: TN919.81

文献标志码: A

Large-Model-Guided Robust Joint Source-Channel Coding for Noisy Channels

GONG Chuqi, GUO Caili, DING Kuiyuan, SUN Qizheng

(School of Information and Communication Engineering, Beijing University of Posts and Telecommunications, Beijing 100876, China)

Abstract: Large-scale models significantly enhance the semantic representation and understanding capabilities of semantic communication systems; however, their massive parameter sizes lead to substantial computational overhead and inference latency, which limit practical applicability. Although knowledge distillation can transfer knowledge from large-scale models to lightweight encoders to reduce model size and complexity, it often degrades system robustness under low signal-to-noise ratio (SNR) conditions. To address this issue, a robust self-knowledge-distilled encoding algorithm is proposed. The method fine-tunes a large-scale model and, for the semantic features encoded by the model, introduces two structurally identical decoders at the receiver to separately predict decoding outputs under noise-free and noisy transmission conditions. The decoder corresponding to the noise-free condition serves as the teacher model and guides the training of the noisy decoder through a self-distillation mechanism, thereby enhancing the decoder's robustness to channel noise. On this basis, the semantic representation capability of the large-scale model is distilled into a lightweight encoder, and during inference, the noise-robust decoder obtained through fine-tuning is employed for semantic decoding. Experimental results demonstrate that the proposed algorithm can increase the accuracy of image classification tasks by approximately 2.5 times under extremely low signal-to-noise ratio conditions.

收稿日期: 2025-09-22

基金项目: 国家自然科学基金项目(62371070)

作者简介: 弓楚琦(2002—), 男, 硕士生。

通信作者: 郭彩丽(1977—), 女, 教授, 博士生导师, 邮箱: guocaili@bupt.edu.cn。

Key words: semantic communications; knowledge distillation; channel noise; large-scale models

第6代无线通信技术(6G, sixth-generation)旨在实现万物智联、数字孪生的美好愿景^[1-2],但对频谱等无线通信资源的需求进一步增长,而现有通信技术几乎已经接近香农物理层的极限^[3]。语义通信(SC, semantic communications)通过传输原始数据的意义而非原始数据,能够减少冗余并降低对频谱资源的需求,有望突破香农极限^[4],为未来6G的智能化、高效化提供了潜在的解决方案。

香农指出,如果信源冗余与信道的统计特性相匹配,为对抗信道噪声,则无需消除源冗余^[5]。因此,联合信源信道编码(JSCC, joint source channel coding)成为研究热点。随着深度学习(DL, deep learning)技术的发展,基于DL的JSCC可以更高效地压缩信源和实现更好的抗噪性能^[6]。但一般Deep JSCC方法多依赖特定任务和数据训练,语义理解能力有限。

近年来,大模型例如对比语言-图像预训练(CLIP, contrastive language image pre-training)模型^[7]和生成式预训练模型-4(GPT-4, generative pre-trained transformer-4)^[8]拥有强大的跨模态处理能力和上下文理解能力,并逐渐引入到语义编解码中的研究与应用中。Liang等^[9]提出了一种基于生成式人工智能驱动的SC系统网络架构,极大地增强了SC系统有效传输内容的能力。大语言模型驱动的SC系统^[10](LaMoSC, large language model-driven semantic communication system)建立了一种多模态融合的SC编解码框架,利用多模态特征来重建原始视觉信息,提高SC系统传输质量。然而,大模型通常包含数千万及以上的参数,直接应用在SC系统中会带来巨大的计算开销和计算时延,尤其是在边缘部署场景下,边缘设备的算力和功率很难满足大模型的有效运行需求。目前已有相关研究来提高大模型指导的SC系统编码的实用性。例如Ni等^[11]提出了多任务SC系统(MTSC, multi-task SemCom),使用自适应模型压缩方法和联邦分割微调来促进在资源受限网络部署基于大模型指导的SC系统。

知识蒸馏^[12](KD, knowledge distillation)是一种有效的大模型轻量化方法,但直接将大模型蒸馏为小规模语义编码器会降低SC系统在较差信道条件下对信道噪声的鲁棒性^[13]。Ding等^[13]提出了

大模型指导下的鲁棒KDSC(RKD-SC, large scale model enabled semantic communications based on robust knowledge distillation),使用KD将大模型知识迁移到小参数量模型中,同时构建信道感知自编码器(CAA, channel-aware autoencoder)用于提高系统的鲁棒性,但该方法引入的CAA会带来额外的计算开销。当前基于大模型KD的JSCC系统,仍然缺乏应对信道噪声导致鲁棒性下降的有效解决方案。

基于上述问题,提出了大模型指导下的鲁棒自KD(RSKD, robust self-knowledge distillation)编码算法。一方面,该算法将大模型KD到轻量化语义编码器,让编码器充分学习大模型优秀的语义表征和理解能力,提高了轻量化编解码器高信噪比(SNR, signal-to-noise ratio)下的性能。另一方面,该算法利用了双解码器自蒸馏,提高了编解码器在低SNR下的鲁棒性。

1 大模型指导下的RSKD编码算法

所提算法结构如图1所示,编解码器均由深度神经网络构成,其中教师模型为大模型,是一个预训练的大规模视觉变换器(ViT, vision transformer)^[14]模型,学生模型为小参数量模型,解码器是对压缩语义特征执行任务处理的轻量化模型。教师模型首先将输入图像进行图块分割,并通过图块嵌入映射为向量序列;随后,引入[CLASS]词元并结合位置编码,以保留图像的全局与空间信息。序列进入Transformer编码器后,利用自注意力机制进行上下文建模,最终完成特征提取。算法训练包含2个步骤。首先,微调教师模型,构建双解码器结构,2个解码器输出之间通过自蒸馏的方式训练,以提高编解码器对信道噪声的鲁棒性。其次,知识迁移教师模型到学生模型,在保留大模型优秀的语义表征和理解能力的同时,实现大模型的轻量化。在推理阶段,发送端图像经过预处理后由轻量化学生模型压缩编码,经过无线信道后由接收端加噪编码器接收特征并解码输出。

1.1 微调教师模型

教师模型采用大模型,大模型一般在大量数据上训练,具备较优的泛化性,但迁移到具体数据场景中时,表现不一定优于在该场景下的专家模型。同时,希望蒸馏教师模型后的学生模型具备对信道噪




图 1 大规模模型指导下的 RSKD 编码算法框架

声的鲁棒性,因此该算法先微调教师模型。

为实现编码器和解码器的联合训练,将物理信道作为网络模型的一层。训练时选择加性高斯白噪声(AWGN, additive white Gaussian noise)信道作为信道层。现有减轻信道噪声影响的方法^[15-16]通常采用基于固定 SNR 训练的策略网络。然而实际场景中精确估计 SNR 往往具有挑战性。为此在训练过程中采用不依赖先验信道知识的训练策略,使编解码器能动态适应信道特性^[13]。具体而言,在 AWGN 信道递减的 SNR 序列下训练,使编解码器充分学习抵抗信道噪声能力。

在训练阶段,对于包含 M 个样本的任务数据集 $D_I = \{I^{(k)}, k = 1, 2, \dots, M\}$ 的第 k 个样本 $I^{(k)}$,任务输入 $I^{(k)}$,经过图像预处理后,由发送端编码器 f_{θ_t} 提取语义信息,压缩原始信息后得到特征 $z_t^{(k)}$, $z_t^{(k)}$ 可以表示为

$$z_t^{(k)} = f_{\theta_t}(I^{(k)}) \quad (1)$$

其中 f_{θ_t} 是以 θ_t 为参数的教师模型编码器。

经过物理信道得到的输出 $\hat{z}_t^{(k)}$ 可以表示为

$$\hat{z}_t^{(k)} = H z_t^{(k)} + N \quad (2)$$

其中 H 为信道系数, $N \sim \mathcal{CN}(0, \sigma_n^2)$, σ_n^2 为噪声方差。

训练时接收端由 2 个相同结构的解码器构成,接收到 $\hat{z}_t^{(k)}$ 后经过加噪解码器 f_{ϕ} 的输出为 $\hat{y}_t^{(k)}$,接收到 $z_t^{(k)}$ 经过无噪解码器 f_{ϕ} 的输出为 $y_t^{(k)}$ 。 $\hat{y}_t^{(k)}$ 可以表示为

$$\hat{y}_t^{(k)} = f_{\phi}(\hat{z}_t^{(k)}) \quad (3)$$

其中 f_{ϕ} 是以 ϕ 为参数的解码器。 $y_t^{(k)}$ 可以表示为

$$y_t^{(k)} = f_{\phi'}(z_t^{(k)}) \quad (4)$$

其中 $f_{\phi'}$ 是以 ϕ' 为参数的解码器。

2 个解码器输出之间通过自蒸馏的方式来增强鲁棒性,将无噪解码器作为教师模型,通过 KD 损失函数指导加噪编码器学习其输出显著性。2 个解码器都通过任务损失函数在任务数据集上实现与真实标签差别最小化。训练时总语义损失函数 L_{RSKD} 可以表示为

$$L_{\text{RSKD}} = \alpha L_{\text{KD}}(\hat{y}_t^{(k)}, y_t^{(k)}) + \beta L_{\text{TASK}}(\hat{y}_t^{(k)}, T^{(k)}) + \gamma L_{\text{TASK}}(y_t^{(k)}, T^{(k)}) \quad (5)$$

其中 $T^{(k)}$ 是任务真实标签, α, β 和 γ 为超参数用来平衡损失函数 L_{KD} 和损失函数 L_{TASK} , L_{KD} 为均方误差 (MSE, mean squared error), L_{KD} 可以表示为

$$L_{\text{KD}} = \frac{1}{M} \sum_{k=1}^M \|y_t^{(k)} - \hat{y}_t^{(k)}\|^2 \quad (6)$$

对于图像分类任务, L_{TASK} 通常为交叉熵 (CE, cross-entropy), L_{TASK} 可以表示为

$$L_{\text{TASK}} = - \sum_{i=1}^M t_i \ln p_i \quad (7)$$

其中 M 表示分类任务的总类别数, t_i 表示真实标签在第 i 类的取值,通常会对真实标签使用独热编码,因此 t_i 通常取值为 0 或 1, p_i 为模型预测第 i 类的概率, p_i 由解码器输出经过 Softmax 函数归一化处理得到。

1.2 KD

固定微调教师模型参数后进行 KD,得到学生模型。在 KD 中,对于第 k 个样本 $I^{(k)}$,图像预处理后,经过教师模型 f_{θ_t} 后得到特征 $z_t^{(k)}$,经过学生模型 f_{θ_s} 得到的特征为 $z_s^{(k)}$ 。

两者间蒸馏损失函数可以表示为

$$L_{\text{KD}} = \frac{1}{M} \sum_{k=1}^M \|z_t^{(k)} - z_s^{(k)}\|^2 \quad (8)$$

1.3 推理

在 KD 过程中,学生模型充分学习到了教师模型的语义表征和语义理解能力,所以解码器无需重新训练,直接使用微调教师模型时训练得到的解码器。考虑信道噪声,因此推理中使用加噪编码器作为学生模型解码器,无噪解码器不参与推理过程。

在推理阶段,对于任务输入 $I^{(k)}$,经过图像预处理后,由编码器 f_{θ_s} 压缩编码后得到特征 $z_s^{(k)}$, $z_s^{(k)}$ 经过物理信道得到 $\hat{z}_s^{(k)}$, $\hat{z}_s^{(k)}$ 经过解码器 f_{ϕ} 输出 $\hat{y}_s^{(k)}$,最后 $\hat{y}_s^{(k)}$ 进行 Softmax 归一化处理后判别分类。RSKD 编码算法同时利用了编解码器来学习对信道噪声的鲁棒性。

1.4 算法步骤

算法1 RSKD 编码算法

输入:包含 M 张图像的数据集 $D_I = \{I^{(k)}, k=1, 2, \dots, M\}$, SNR 序列和物理信道,损失函数 L_{RSKD} 中超参数 α, β 和 γ 的值,教师模型参数 θ_t 、学生模型参数 θ_s 、加噪解码器参数 ϕ 和无噪解码器参数 ϕ'

```

1 初始化训练的 SNR 序列和物理信道
2 初始化解码器参数  $\phi$  和  $\phi'$ 
3 for  $i \in \text{SNR}$  do
4   for all  $x \in \{I^{(k)}, k=1, 2, \dots, M\}$  do
5     图像压缩编码  $z_t \leftarrow f_{\theta_t}(x)$ ;
6     经过物理信道传输输出  $\hat{z}_t$ ;
7     无噪解码器  $f_{\phi'}$  输出  $y_t \leftarrow f_{\phi'}(z_t)$ ;
8     加噪解码器  $f_{\phi}$  输出  $\hat{y}_t \leftarrow f_{\phi}(\hat{z}_t)$ ;
9     根据式(5)计算损失函数  $L_{\text{RSKD}}$ ;
10     $L_{\text{RSKD}}$  反向传播并更新参数  $\theta_t, \phi$  和  $\phi'$ ;
11  end for
12 end for
13 初始化学生模型参数  $\theta_s$ , 固定教师模型参数  $\theta_t$ ;
14 repeat
15   for all  $x \in \{I^{(k)}, k=1, 2, \dots, M\}$  do
16     教师模型图像压缩编码  $z_t \leftarrow f_{\theta_t}(x)$ ;
17     学生模型图像压缩编码  $z_s \leftarrow f_{\theta_s}(x)$ ;
18     根据式(8)计算蒸馏损失函数  $L_{\text{KD}}$ ;
19      $L_{\text{KD}}$  反向传播并更新参数  $\theta_s$ ;
20   end for
21 until 收敛

```

输出:学生模型参数 θ_s 和加噪解码器参数 ϕ

RSKD 编码算法具体流程为所述算法 1。首先初始化训练的信道环境和 SNR 序列(即第 1 行)。接着初始化解码器参数(即第 2 行)。然后通过语义损失函数在任务数据集下微调教师模型参数(即第 3~12 行),最后通过 KD 得到学生模型(即第 13~21 行)。

2 实验结果与分析

2.1 实验设置

数据集:采用加拿大高等研究院-100 (CIFAR-100, Canadian institute for advanced research-100) 分类数据集,该数据集共有 100 类别。

编码器:对于大模型即教师模型,采用 CLIP 模型的图像编码器 CLIP ViT-B/32,参数量为 87.85 M。对于学生模型,采用的是小型残差网络,参数量为 2.92 M。

解码器:采用的是一个单独的线性层,由于没有使用激活函数,因此解码器只具备线性变化。

训练的 SNR 序列:[20, 10, 5, 0, -5, -10] dB, 每个 SNR 训练 3 个轮次。

损失函数 L_{RSKD} 超参数: $\alpha = 0.4, \beta = 0.4, \gamma = 0.2$ 。

学生模型结构细节如表 1 所示。其采用的激活函数为线性整流函数(ReLU, rectified linear unit),并使用了残差连接,输出形状中 B 表示批次, C 表示通道数, H 表示高度, W 表示宽度。

表 1 学生模型架构

层	输出形状	详情
残差块		
二维卷积	$[B, C, H, W]$	卷积核 3×3 , 步幅 = 2
二维卷积	$[B, C, H, W]$	卷积核 3×3 , 步幅 = 1
相加 + ReLU	$[B, C, H, W]$	跳跃连接
学生模型		
二维卷积	$[B, 16, H, W]$	卷积核 3×3 , 步幅 = 1
二维最大池化	$[B, 16, H/2, W/2]$	卷积核 3×3 , 步幅 = 2
第 1~4 层	可变(见详情)	每层 2 个残差块, 输出通道: $32 \rightarrow 64 \rightarrow 128 \rightarrow 256$
平均池化	$[B, 256, 1, 1]$	全局平均池化
全连接	$[B, 512]$	全连接层

2.2 实验基线

为保证对比的公平性和评估所提算法 RSKD 的性能,实验采用以下基线。

- 1) RKD-SC^[13]:蒸馏教师模型到学生模型,采用CAA来提高SC系统的鲁棒性。
- 2) Deep JSCC:编解码器结构与RSKD一致,端到端(E2E, end-to-end)无噪直接训练得到编解码器。
- 3) 实时SC系统(RTSC, real-time semantic communications)^[17]:基于深度神经网络ViT构建的RTSC。
- 4) 面向任务的深度学习赋能SC(T-DeepSC, task-oriented deep learning enabled semantic communication)^[18]:选择基于图像分类任务的T-DeepSC分别在SNR为-2 dB和12 dB信道条件下训练。

2.3 实验结果分析

2.3.1 RSKD 的鲁棒性

图 2 对比了在 AWGN 信道、瑞利 (Rayleigh fading) 信道和莱斯 (Rician fading) 信道下 RSKD 和基线在不同 SNR 下图像的分类正确率。如图 2(a) 所示,RSKD 在低 SNR 下正确率最高,鲁棒性最好。

例如,在 SNR 为 -20 dB 时,RSKD 的正确率为 25.09%, 相比 RKD-SC 正确率提升了 87.8%。RSKD 与 Deep JSCC (E2E) 相比,正确率提升了 92.1%,这验证了在相同参数量下,RSKD 对信道噪声具备更好的鲁棒性。RSKD 采用了递减 SNR 序列训练方案和双解码器自蒸馏的训练结构,充分利用了编解码器应对信道噪声,具备对恶劣信道噪声的适应能力。在 SNR 为 22 dB 时,RSKD 与 Deep JSCC (E2E) 相比,正确率提升了 12.3%,这是由于 RSKD 编码器由大模型 KD 得到,在 KD 过程中 RSKD 编码器充分学习到了大模型优秀的语义表征和理解能力,因此在高 SNR 下,具备更佳语义提取能力编码器的 RSKD 表现自然优于没有大模型指导的 Deep JSCC (E2E)。大模型 KD 到轻量的语义编码器能够带来良好 SNR 下的性能增益,但是会降低系统对信道噪声的鲁棒性,在 KD 的基础上,提出的 RSKD 算法可以在不增加任何推理复杂度的基础上,增加系统低 SNR 下的鲁棒性。




图 2 不同信道下各种方法正确率对比

瑞利信道和莱斯信道的结果是 20 次独立实验的平均值。如图 2(b) 所示,RSKD 和基线在不同 SNR 下正确率与 AWGN 信道呈现相似的结果。RSKD 鲁棒性仍然最佳,在 SNR 为 -20 dB 的信道条件下,在任务数据集上的正确率为 22.53%。在莱斯信道下,将直射路径与多径散射分量的功率比 K 因子设置为 1,即 0 dB,即直射分量与散射分量的平均功率相同。如图 2(c) 所示,在 SNR 为 -20 dB 的信道条件下,RSKD 鲁棒性在各种方法中最佳,与 AWGN 信道和瑞利信道一致,在任务数据集上正确率为 22.84%。实验结果表明,RSKD 对不同信道环

境的适应能力较好,在不同信道环境下可以保证通信系统对信道噪声的高鲁棒性。

2.3.2 RSKD 的消融实验

为探究 RSKD 编码算法对鲁棒性的贡献,采用消融实验来评估使用和未使用 RSKD 编码算法之间的差异。对于采用教师模型为编码器,使用 RSKD 编码算法微调得到有 RSKD 的教师模型,不使用 RSKD 编码算法微调得到无 RSKD 的教师模型。对于采用学生模型为编码器,KD 无 RSKD 的教师模型,固定编码器参数,解码器使用 RSKD 编码算法训练得到有 RSKD 的学生模型,解码器不使用 RSKD

编码算法训练得到无 RSKD 的学生模型。

由于 3 个信道各基线结果相似,仅分析 AWGN 信道。如图 3(a) 所示,在 SNR 为 -20 dB 时,有 RSKD 的教师模型鲁棒性最佳,正确率为 25.83%,比无 RSKD 的教师模型正确率提高了 201.8%,验证了 RSKD 编码算法提高了编解码器在低 SNR 下的鲁棒性。RSKD 继承了有 RSKD 的教师模型对信

道噪声的高鲁棒性。在 SNR 为 -20 dB 时,RSKD 比无 RSKD 的学生模型正确率提高了 248.5%,性能相对提升了约 2.5 倍。有 RSKD 的学生模型与 RSKD 的鲁棒性仍有一定差距,因为 RSKD 编码算法在训练过程中利用编解码器共同应对信道噪声,抗噪声性能自然更佳。




图 3 不同信道下消融实验正确率对比

2.3.3 RSKD 的收敛性

为了进一步体现 RSKD 的抗噪声性能,对比了在动态 SNR 序列下,RSKD 和 RKD-SC 的 CE 损失函数收敛情况。实验中,SNR 每训练 3 个轮次下降 5 dB,并在图 4 中用 S 表示。如图 4 所示,RSKD 在整个训练过程中的 CE 损失函数值要低于 RKD-SC 的 CE 损失函数值,且更加稳定,波动较小;在 SNR 为 -10 dB 时,RKD-SC 的 CE 损失函数值随着训练越来越大,CE 损失函数发散;RSKD 的 CE 损失函数值虽然增大,但没有随着训练而发散。以上结果表明,RSKD 在较低 SNR 下训练时,可以更好收敛及更高效地学习抗噪声能力。




图 4 RSKD 与 RKD-SC 的 CE 对比

2.3.4 RSKD 的表征能力

为了体现 RSKD 编码算法对数据更加高效的语

义表征和理解能力,对比了大模型指导的 RSKD 和无大模型参与的 Deep JSCC (E2E)的数据利用率。

选取 CIFAR-100 训练集的子集来训练,训练得到的编解码器在整个测试集上的正确率可以反映数据利用率。如图 5 所示,在任意数据量的子集下,RSKD 的数据利用率都要超过 E2E 训练的 Deep JSCC (E2E)。例如在使用 30k 张图像时,相比 Deep JSCC (E2E),RSKD 的正确率提升了 15.6%,达到其使用全部训练集训练正确率的 94.21%,而 Deep JSCC (E2E) 达到其使用全部训练集正确率的 91.57%。此外,在使用全部训练集训练时,RSKD 数据利用率性能相较于 Deep JSCC (E2E) 提升了 12.3%。RSKD 通过 KD 让小参数量模型即学生模型充分学习了大模型优秀的语义表征和语义理解能力,因此相同的数据量上 RSKD 数据利用率更高。

2.3.5 RSKD 的 E2E 推理时间

为了说明 RSKD 在构建低时延 SC 系统上的优势,对比了各种方法千兆浮点运算次数 (GFLOPs, giga floating-point operations)、模型参数量和 E2E 推理时间。推理任务在配备有中央处理器 (CPU, central processing unit) Intel Xeon Gold 6130 和单张图形处理器 (GPU, graphics processing unit) NVIDIA GeForce RTX 4090 的硬件平台上运行。E2E 推理时间通过多次测量取均值测算。如表 2 所示,RSKD 正确率在达到有 RSKD 的教师模型的 82.97% 的同




图 5 RSKD 和 Deep JSCC (E2E) 的数据利用率对比

时,减少了编码器 96.67% 的模型参数量,E2E 推理时间由 353.35 μ s 缩短到 70.97 μ s,缩短了 79.91%;RSKD 的模型结构和较小参数量让其在推理过程中产生的中间特征维度更小,峰值内存占用更低,并且 GFLOPs 与有 RSKD 的教师模型相比减小了 94.89%,能耗更低;RSKD 相较于 RKD-SC 没有 CAA 结构,参数量更小,推理时间缩短了 37.86%,两者 GFLOPs 相近。RSKD 由于参数量小,在推理过程中会占用更少的运算内存,减少能耗和 E2E 推理时间。RTSC 拥有最小的参数量,使得 GFLOPs 和 E2E 推理时间最小,但这种优势是以牺牲性能为代价的。

表 2 不同方法 GFLOPs、参数量和 E2E 时间对比

方法	GFLOPs	参数量/M	E2E 时间/ μ s
RSKD	0.442	2.92	70.97
RKD-SC	0.451	11.33	114.21
RTSC	0.071	0.73	9.62
T-DeepSC	2.266	8.89	105.95
有 RSKD 的教师模型	8.643	87.85	353.35

2.3.6 RSKD 在文本语义传输任务中的表现

为进一步研究 RSKD 泛化到其他智能任务的能力,在文本语义传输任务上进一步测试了 RSKD 方法的性能。如图 6 所示,在文本语义传输任务中,选取 DeepSC^[19] 方法作为对比的基线方法,对比了 DeepSC 在使用原信道编解码器(CC, channel codec)和使用所提 RSKD 方法 DeepSC 的性能。如图 6 所示,相较于原 CC,RSKD 算法可以帮助 DeepSC 系统在较低 SNR 下具备对信道噪声更好的鲁棒性。实验中,采用双语评估替补(BLEU, bilingual evaluation understudy)分数的一元语法(1-grams)作为传输质量的评估指标。实验结果表明,

有 RSKD 的 DeepSC 在 SNR 为 -10 dB 下 BLEU (1-grams) 达到 0.231,相较于有 CC 的 DeepSC 提升了 84.6%。上述结果说明,所提 RSKD 方法可适用在不同模态的多种智能任务上,有良好的泛化能力。




图 6 在 AWGN 信道下 RSKD 的文本语义传输任务性能

3 结束语

为提高大模型 KD 后轻量化 SC 系统的鲁棒性,提出了 RSKD 编码算法。该算法通过双解码器自蒸馏结构训练来提升编解码器对信道噪声鲁棒性,同时没有增加参数量。在多个智能任务、多种信道类型下测试了所提算法的性能。实验结果表明,所提算法可应用于包括图像分类、文本语义传输等多种智能任务,同时在多种信道类型下保持 SC 系统对信道噪声的高鲁棒性,便于低时延 SC 系统的构建。下一步工作可探索更加灵活的蒸馏策略,并考虑多模态 SC 场景,以进一步拓展和验证所提算法的适用性与有效性。

参考文献:

[1] SHI Y, ZHOU Y, WEN D, et al. Task-oriented communications for 6G: vision, principles, and technologies [J]. IEEE Wireless Communications, 2023, 30(3): 78-85.

[2] YANG W, DU H, LIEW Z Q, et al. Semantic communications for future Internet: fundamentals, applications, and challenges [J]. IEEE Communications Surveys and Tutorials, 2022, 25(1): 213-250.

[3] LUO X, CHEN H H, GUO Q. Semantic communications: overview, open issues, and future research directions [J]. IEEE Wireless Communications, 2022, 29(1): 210-219.

[4] NIU K, ZHANG P. A mathematical theory of semantic communication [EB/OL]. (2024-01-24) [2025-07-10]. <https://arxiv.org/abs/2401.13387>.

- [5] SHANNON C E. A mathematical theory of communication [J]. The Bell System Technical Journal, 1948, 27(3): 379-423.
- [6] BOURTSOULATZE E, KURKA D B, GÜ N Z D, et al. Deep joint source-channel coding for wireless image transmission[J]. IEEE Transactions on Cognitive Communications and Networking, 2019, 5(3): 567-579.
- [7] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C] // Proceedings of the 38th International Conference on Machine Learning. [S. l.]: PMLR, 2021: 8748-8763.
- [8] OPENAI. GPT-4 technical report[EB/OL]. (2023-03-15)[2025-07-10]. <https://arxiv.org/abs/2303.08774>.
- [9] LIANG C, DU H, SUN Y, et al. Generative AI-driven semantic communication networks: architecture, technologies and applications[J]. IEEE Transactions on Cognitive Communications and Networking, 2025, 11(1): 27-47.
- [10] ZHAO Y, YUE Y, HOU S, et al. LaMoSC: large language model-driven semantic communication system for visual transmission[J]. IEEE Transactions on Cognitive Communications and Networking, 2024, 10(6): 2005-2018.
- [11] NI W, QIN Z, FENG Y, et al. Multi-task semantic communications via large models[J]. IEEE Communications Standards Magazine, 2025, 9(4): 16-23.
- [12] HINTON G, VINYALS O, DEAN J, et al. Distilling the knowledge in a neural network[EB/OL]. (2015-03-09) [2025-08-15]. <https://arxiv.org/abs/1503.02531>.
- [13] DING K, LIU F, YANG Y, et al. Large scale model enabled semantic communications based on robust knowledge distillation[C] // GLOBECOM 2024: 2024 IEEE Global Communications Conference, Cape Town, South Africa: IEEE, 2024: 5235-5240.
- [14] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16 × 16 words: transformers for image recognition at scale[EB/OL]. (2020-10-22)[2025-08-20]. <https://arxiv.org/abs/2010.11929>.
- [15] XU J, AI B, CHEN W, et al. Wireless image transmission using deep source channel coding with attention modules[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(4): 2315-2328.
- [16] YANG M, KIM H S. Deep joint source-channel coding for wireless image transmission with adaptive rate control [C] // ICASSP 2022: 2022 IEEE International Conference on Acoustics, Speech and Signal Processing, Singapore: IEEE, 2022: 5193-5197.
- [17] YOO H, JUNG T, DAI L, et al. Demo: real-time semantic communications with a vision transformer[C] // ICC 2022 Workshops: 2022 IEEE International Conference on Communications Workshops, Seoul, South Korea: IEEE, 2022: 1-2.
- [18] ZHANG G, HU Q, QIN Z, et al. A unified multi-task semantic communication system for multimodal data[J]. IEEE Transactions on Communications, 2024, 72(7): 4101-4116.
- [19] XIE H Q, QIN Z J, LI G Y, et al. Deep learning enabled semantic communication systems[J]. IEEE Transactions on Signal Processing, 2021, 69: 2663-2675.